IA local no ESP32-S3

Plano visual, ensaio em QEMU e opções reais para um tutor físico em português.



DECISÃO EM 1 MINUTO

EVIDÊNCIA DESTA RODADA

O firmware de laboratório **inicializou no QEMU** com 8 MB de PSRAM simulados. Três tamanhos de arena couberam em etapas; dois grandes, juntos, não. Uma voz PT gerou WAV no Mac. **Áudio, IA e tela reais não rodaram no ESP.**

A / RECOMENDADA

Tutor offline guiado

Tela e touch conduzem explicações e quizzes com conteúdo no SD. Áudios gravados; microfone registra tentativas.

B / PESQUISA

Voz livre toda no ESP

Exige ASR aberto em PT, síntese PT embarcada e prova de qualidade/latência. Não há pilha PT validada nesta bancada.

C / REFERÊNCIA

ESP + computador/celular

O dispositivo mantém o toque e áudio; outro aparelho executa ASR e respostas. É a rota de melhor capacidade imediata.

VEREDITO

É possível criar um produto **100% offline no ESP32-S3** se a experiência for guiada e o conteúdo fechado. A promessa de conversa aberta em português, com compreensão e fala de qualidade, permanece uma **hipótese de P&D**. Para o próximo protótipo, escolher A e investigar B em paralelo.

O que existe e o que coube

Arquitetura atual, mudança de hardware e leitura correta do teste de memória.

HOJE

ESP32-S3

LCD ILI9341 240×320 + touch XPT2046; controle por USB.

USB →

MAC

Microfone, faster-whisper em PT, análise lexical e SQLite.

PARA FICAR AUTÔNOMO

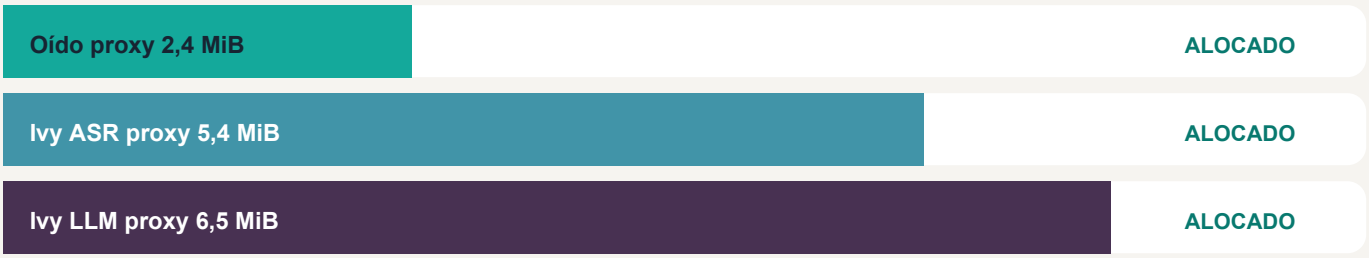
Adicionar captura I2S real, amplificador/alto-falante, SD, pinagem validada e software de áudio/consulta. O módulo já reportou 8 MB de PSRAM em teste anterior; flash física não foi confirmada nesta rodada.

PSRAM EMULADA: 8.388.608 BYTES

Após anel PCM + índice + faixa LCD



Alocações separadas, com liberação entre etapas



5,4 + 6,5 MiB AO MESMO TEMPO

O segundo bloco não foi alocado. Os blocos são apenas reservas de memória; **nenhum peso, inferência ou periférico de áudio foi executado no QEMU**. O QEMU não substitui ensaios de I2S, LCD SPI, touch e SD da placa real. [E1, F1]

PARTIÇÃO DE FLASH ATUAL

Build configurado em **2 MB**; partição do app em **1 MB**. O laboratório compilou com 217.888 B. Isso não comprova o tamanho físico da flash da placa.

UM AJUSTE DE PINAGEM

No protótipo, GPIO6 aparece como IRQ do touch (usado por polling). Um exemplo antigo de microfone também sugere GPIO6. Escolher pinos pela placa e pelo circuito antes de ligar o I2S.

Qual IA usar em cada etapa?

Decisão por idioma, maturidade e função pedagógica - não apenas por tamanho do arquivo.

01 OUVIR

ESP-SR MultiNet

Comandos em inglês/chinês, até 200 frases. Não transcreve livremente em PT.

Não usar para fala livre PT.

01 OUVIR

Oído Conformer-CTC

ASR aberto em inglês/espanhol; pesos 8,3 a 15,3 MB. Pico de trabalho de 2,4 MB publicado em QEMU.

Candidato de motor; exigiria adaptação/treino PT.

02 PENSAR

Busca + regras locais

Conteúdo curricular fechado no SD, respostas ancoradas em trechos e quizzes determinísticos.

Escolha do MVP offline.

02 PENSAR

Ivy TinyTalk 19,7M

Assistente offline em inglês, ~6,5 MB de arena; autor reporta 5,4-5,9 tokens/s na própria placa.

Pesquisa futura; não há validação de tutoria PT.

03 FALAR

Áudio gravado / sanoTTS PT

pt-cadu-small: 512 mil parâmetros, 1,02 MB fp16. Gerou 3 WAVs no Mac; inteligibilidade não medida.

WAV primeiro; portar PT após prova física e revisão de licença.

Escolha objetiva: produto A = sem LLM e sem ASR livre; produto B = primeiro obter ASR PT medido, depois avaliar TTS PT, e só então um gerador pequeno.

Fontes técnicas: [F2] MultiNet, [F3] Oído, [F4] Ivy, [F5-F6] sanoTTS/PT.

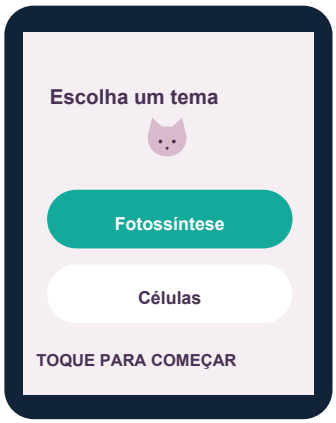
Como o gatinho funcionaria

A opção A preserva a presença física do NekoMind e produz uma jornada offline completa.

1 ESCOLHER

Tocar em um tema

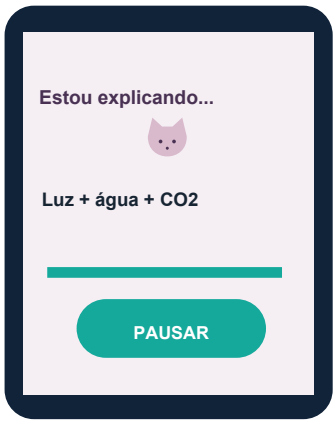
Conteúdo curto do SD; tela mostra origem e duração.



2 EXPLICAR

Ouvir e acompanhar

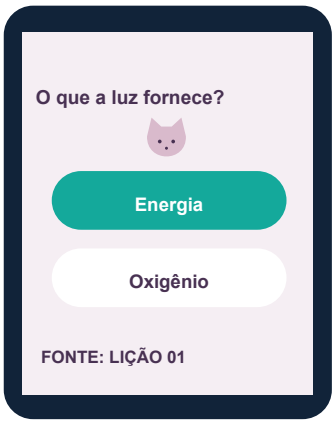
Áudio curto + texto; microfone pode ser usado para gravar uma tentativa.



3 PRATICAR

Responder no touch

Quiz com correção vinculada ao trecho estudado.



SE O ALUNO FALAR LIVREMENTE

No MVP, a gravação pode ser reproduzida ou exportada, mas o dispositivo **não deve fingir que entendeu**. A transcrição PT no ESP é o principal experimento da opção B. Uma resposta sem evidência deve dizer “não sei” e sugerir o tópico relevante.

VALOR DE PRODUTO

Aparelho dedicado para estudar sem notificações, com toque grande, voz curta e feedback imediato. A utilidade vem do ritual de estudo e do conteúdo verificável.

LIMITE DA TELA

240×320 px pedem frases curtas, poucos botões e redraw parcial. Captura, desenho e áudio competem por tempo de CPU e barramentos; medir isso em placa.

O fluxo que precisa ser provado

Fases sequenciais, conteúdo local e periféricos reais; SD guarda dados, não amplia RAM.

Emulado: boot, reservas/liberação e busca lexical com texto injetado. **Não emulado:** I2S, SD, LCD, ASR e TTS reais.

MIC + I2S
PCM 16 kHz

▶

ESCUTA
VAD / botão

▶

ENTRADA
menu ou ASR PT

▶

RESPOSTA
busca + fonte

▶

SAÍDA
LCD + áudio

CONTROLE DE MEMÓRIA

Reservar buffers pequenos de captura e LCD. Carregar **uma fase por vez**: ouvir → liberar arena → recuperar conteúdo → falar → liberar arena. Manter um único orçamento de pico e registrar free/largest/minimum em cada transição. A tentativa conjunta de 5,4 + 6,5 MiB falhou no QEMU. [E1, F4]

INTEGRAÇÃO FÍSICA - QUATRO CONEXÕES A VALIDAR

1

LCD + TOUCH

SPI2 partilhado; LCD GPIO 11/12/13, CS10; touch CS7. Medir disputa com SD.

2

MICROFONE

I2S digital + DMA; driver no repositório ainda é stub. Definir três pinos livres.

3

ALTO-FALANTE

Saída I2S para DAC/amplificador externo, mais alimentação e limite de volume.

4

SD + FLASH

Guardar lições/modelos e versões. Confirmar flash física e refazer partições.

Não foram medidos nesta rodada: consumo, temperatura, FPS, latência I2S/SD, ruído ou autonomia.

Ensaios em ordem de decisão

Cada etapa produz uma prova observável e pode encerrar uma opção antes de gastar mais esforço.

0

Inventário da placa

Ler flash/PSRAM reais; confirmar mic, amplificador, fonte, SD e GPIO.

Gate: mapa elétrico sem conflito; partição adequada.

1

Áudio físico

Capturar PCM, tocar WAV, gravar/reproduzir e medir ruído/volume.

Gate: amostra inteligível sem travar LCD/touch.

2

Produto offline A

Lições no SD, tela, quiz, áudio gravado e resposta com fonte.

Gate: fluxo completo sem Mac nem Wi-Fi.

3

Pesquisa de ASR PT

Portar/treinar candidato; ≥100 falas, ≥5 vozes; medir WER e tempo.

Gate proposto: WER ≤20% limpo; ≤35% ruído moderado.

4

Pesquisa de TTS PT

Portar pt-cadu-small; checar fonemas, RAM, áudio e licenças.

Gate: ≥90% de 30 frases compreendidas por 5 ouvintes; sem OOM.

Critérios 3 e 4 são metas propostas, não resultados. Se falharem, manter o produto A; não prometer conversa livre em PT na demonstração A3.

O que fazer agora

Uma recomendação executável, com as fontes que sustentam cada afirmação técnica.

RECOMENDAÇÃO

Construir primeiro o tutor offline guiado no hardware obrigatório. Tratar voz livre PT no ESP como pesquisa com gate; usar o híbrido como referência funcional se a banca aceitar.

DECISÃO CONDICIONAL

Se a placa tiver flash insuficiente

Confirmar capacidade física. Redesenhar partições ou usar variante com flash maior; SD não substitui o app executável.

Se o ASR PT não atingir o gate

Manter touch como entrada principal; microfone para gravação, revisão ou exportação.

Se a voz PT não rodar bem

Manter áudio gravado com texto na tela; evitar afirmar TTS neural local.

FONTES PRIMÁRIAS E RASTREABILIDADE

[E1] **Laboratório próprio - código + resultado estruturado**
experiments/esp32_s3_offline_lab/results/2026-10-06.json

[F1] **Espressif - QEMU ESP32-S3 / periféricos suportados**
github.com/espressif/esp-toolchain-docs/.../qemu/esp32s3/README.md

[F2] **Espressif - MultiNet (idiomas e comandos)**
docs.espressif.com/projects/esp-sr/.../speech_command_recognition

[F3] **Oído - modelos, memória, idioma e limites**
github.com/lokutor-ai/oido

[F4] **Ivy - arena, velocidade e fluxo em placa**
github.com/iamankushpandit/esp_ai

[F5] **sanoTTS - vozes PT, porta MCU e licenças**
github.com/Ampixa/sanoTTS

[F6] **Pacote da voz pt-cadu-small**
huggingface.co/ampixa/sanoTTS/tree/main/pt-cadu-0p51m

Fontes locais: README.md, docs/esp32-s3-display-touch.md, iot/nekomind_firmware/sdkconfig.

Nota: a rubrica oficial A3 e a pinagem final de microfone/alto-falante não foram entregues aqui. A página Notion foi informada como possivelmente desatualizada. Compatibilidade final depende de placa e ensaio físico.